

# Aprendizado supervisionado 1

Especialização em Ciência de dados, IM/UFRJ  
Thaís C O Fonseca  
DME/UFRJ

# Modelos de regressão linear múltipla



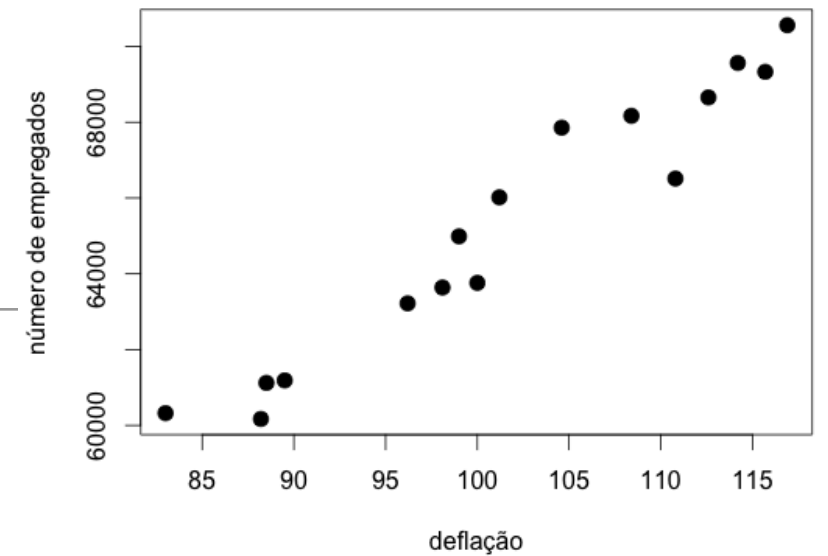
# Exemplo

Considere novamente o exemplo sobre emprego. Além do índice econômico temos disponível também

- o GNP, o produto nacional bruto.
- o número de pessoas com mais de 14 anos de idade.

Seja  $X_1$  o índice econômico de deflação,  $Y$  o número de pessoas empregadas,  $X_2$  o GNP e  $X_3$  o número de pessoas com mais de 14 anos

Existe relação entre  $Y$  e as covariáveis  $X_1$ ,  $X_2$  e  $X_3$ ?



# Modelo de regressão linear múltipla

---

O modelo geral é dado por

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + \epsilon.$$

Nesse caso,

$$E(y \mid x) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k.$$

→ Dizemos que a regressão é linear pois  $E(y \mid x)$  depende de forma linear de  $\beta_0, \beta_1, \dots, \beta_k$ .

O modelo abaixo é linear?

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \epsilon$$

Sim!!!! Basta reescrever

$$x_3 = x_1 x_2.$$

# Notação matricial

---

Para uma amostra de tamanho  $n$ ,  $y_1, \dots, y_n$ , defina:

$\mathbf{y} = (y_1, \dots, y_n)'$   $\rightarrow$  vetor  $n$  por  $1$  de observáveis

$\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_k)'$   $\rightarrow$  vetor  $(p=k+1)$  por  $1$  de coeficientes

$\boldsymbol{\epsilon} = (\epsilon_1, \dots, \epsilon_n)'$   $\rightarrow$  vetor  $n$  por  $1$  de erros

$\mathbf{X} = (\mathbf{1}, x_1, \dots, x_k)$   $\rightarrow$  matriz  $n$  por  $p$  de covariáveis

O modelo é dado por

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

# Interpretação dos coeficientes

---

- Vimos que para cada  $X_{i1}, \dots, X_{ik}$  temos

$$E(y \mid X) = \beta_0 + \beta_1 X_{i1} + \dots + \beta_k X_{ik}$$

Isso significa que para  $X_{i1} = 0, \dots, X_{ik} = 0$  temos

$$E(y \mid X) = \beta_0.$$



Nível comum!

Então  $\beta_0$  é interpretado como o valor esperado de  $y$  para o valor 0 das covariáveis.

# Interpretação dos coeficientes

---

- Considere  $X = X^*$  então

$$E(y \mid X^*) = \beta_0 + \beta_1 X_{i1}^* + \beta_2 X_{i2}^* + \dots + \beta_k X_{ik}^*.$$

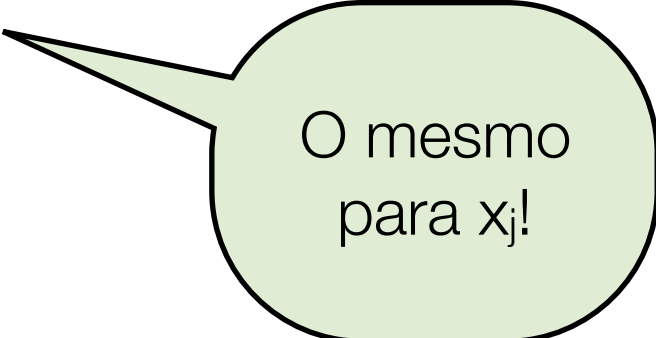
Considere também  $X_{i1} = X_{i1}^* + 1$  e  $X_{i(-1)} = X_{i(-1)}^*$

$$E(y \mid X_{i1}^* + 1, X_{i(-1)}^*) = \beta_0 + \beta_1 (X_{i1}^* + 1) + \beta_2 X_{i2}^* \dots + \beta_k X_{ik}^*.$$

Fazendo a diferença temos

$$E(y \mid X_{i1}^* + 1, X_{i(-1)}^*) - E(y \mid X = X^*) = \beta_1.$$

Então  $\beta_1$  é interpretado como a mudança no valor esperado de  $y$  quando acrescentamos 1 unidade em  $X_1$  para as outras variáveis fixas em uma constante qualquer.



O mesmo  
para  $x_j$ !

# Método de mínimos quadrados

---

Considere uma amostra de tamanho  $n$ .

Queremos encontrar o modelo ajustado

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k$$

que minimiza a soma de quadrados dos erros. Então queremos encontrar  $\boldsymbol{\beta}$  que minimize a função

$$S(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = \sum_{i=1}^n (y_i - (\beta_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_k x_{ik}))^2.$$

Isto é, queremos minimizar

$$S(\boldsymbol{\beta}) = \mathbf{y}'\mathbf{y}' - \boldsymbol{\beta}'\mathbf{X}'\mathbf{y} - \mathbf{y}'\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}$$

Resultando em

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Será  
satisfeito  
quando as  
colunas de  $\mathbf{X}$   
não forem  
linearmente  
dependentes!

Quando a matriz  $(\mathbf{X}'\mathbf{X})^{-1}$   
existe!!!



# Algumas definições

---

- Modelo ajustado

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$

Podemos reescrever

$$\hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{H}\mathbf{y}$$

Matriz H: importante na análise de resíduos.

- Resíduos

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{y} - \mathbf{H}\mathbf{y} = (\mathbf{I}_n - \mathbf{H})\mathbf{y}$$

# Suposições do modelo de regressão múltipla

---

As suposições são as mesmas do modelo simples:

1. Erros tem média zero.  $E(\epsilon) = 0$
2. Variância constante.  $V(\epsilon) = \sigma^2$
3. Erros não correlacionados.  $Cor(\epsilon_i, \epsilon_j) = 0$

Vimos que o modelo para k covariáveis é dado por:

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + \epsilon$$

# Método de máxima verossimilhança

---

$$\begin{aligned} L(\beta, \sigma^2; y, x) &= f(y_1, \dots, y_n; x) \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta) \right\} \end{aligned}$$

Para encontrar o EMV devemos maximizar a função acima.

Isso equivale a encontrar o estimador de mínimos quadrados para  $\beta$ .

Os valores de  $\beta, \sigma^2$  que maximizam a função acima são

$$\begin{aligned} \hat{\beta} &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y} \\ \hat{\sigma}^2 &= \frac{(y - X\hat{\beta})'(y - X\hat{\beta})}{n} \end{aligned}$$

# Exemplo de modelagem (regressão)

# O que afeta o número diário de voos em NY


---

- Vamos considerar os dados do número de voos por dia que saem da cidade de Nova York.
- O conjunto de dados é de pequeno porte: 365 linhas e 2 colunas.


```
# A tibble: 365 x 2
  date          n
  <date>      <int>
1 2013-01-01    842
2 2013-01-02    943
3 2013-01-03    914
4 2013-01-04    915
5 2013-01-05    720
6 2013-01-06    832
7 2013-01-07    933
8 2013-01-08    899
9 2013-01-09    902
10 2013-01-10    932
# ... with 355 more rows
```

# Gráfico da série temporal do número de voos

---



# Dados por dia da semana



- Claro efeito de fim de semana, em particular no sábado.
- Maior parte das viagens devem ser a trabalho.
- Note que o efeito de sábado é bem menor (até mesmo quando comparado a domingo).

- Vamos ajustar um modelo com efeito de dia da semana. Qual é esse modelo?

# Modelo com efeito de dia da semana

---

Neste exemplo temos variáveis dummies indicadoras do dia da semana, com  $I_{mon} = 1$  se segunda-feira e 0 caso contrário.

$$y = X\beta + \epsilon,$$


onde  $X = (I_{sun}, I_{mon}, I_{tue}, I_{wed}, I_{thu}, I_{fri}, I_{sat})$ .

```
Coefficients:
daily$wdaySun  daily$wdayMon  daily$wdayTue  daily$wdayWed  daily$wdayThu
          891.5          974.8          951.4          962.7          965.8
daily$wdayFri  daily$wdaySat
          967.5          744.6
```



# Modelo com efeito de dia da semana


---



- Dados e previsão usando modelo com efeito de dia da semana.

# Resíduos


---



- Resíduos por dia da semana.
- Note que o comportamento no sábado difere dos demais.


# Número de voos aos sábados no “term”

---




- Note os comportamentos bem distintos ao longo do ano.

# Para os outros dias da semana



- O summer term tem número de voo mais altos do que os outros terms.
- Esse efeito deve ser incluído no modelo.


# Modelo com term



- As médias estimadas são afetadas pelos outliers nos dados.


# Resíduos

---



- Agora não vemos mais os efeitos de dia da semana e dos terms.
- Conseguimos ver grandes outliers devido a feriados nacionais. E também uma tendência ao longo do ano.

# Melhorando o modelo



- Gráfico: Modelo ajustado com efeito do dia da semana, com efeito do dia da semana e term e modelo que usa splines (veremos mais a frente esse ajuste).
- Note que o modelo de regressão mantém a interpretabilidade.

# Alguns comentários


---

- Note que algum pensamento crítico foi necessário nesse exemplo para que variáveis explicativas razoáveis fossem sugeridas.
- Um método totalmente automático pode não considerar esses nuances que o cientista de dados fazendo a modelagem deve considerar.
- Isso é verdade mesmo em contexto puramente preditivos.
- O modelo considera observações não correlacionadas, porém temos uma série temporal. O modelo poderia ser melhorado para incluir correlação temporal.



# Regressão: contexto de Estatística x contexto de Machine learning

# Contexto estatístico



Foco na interpretação dos coeficientes, verificação das hipóteses.

- O ajuste da regressão é bom?
- O modelo parece útil para previsão?
- As suposições básicas são válidas?

Os erros têm média 0, variância constante e são não correlacionados?

# Contexto de machine learning

---

- Iremos focar no objetivo preditivo, isto é, no caso de regressão linear onde  $\mathbf{x} = (x_1, \dots, x_p)$  temos

$$g(\mathbf{x}) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_p x_p$$

- Após ajustar o modelo utilizando  $\mathbf{x}_1, \dots, \mathbf{x}_N$ , para novos dados temos

$$g(\mathbf{x}_{N+1}) \approx y_{N+1}, \dots, g(\mathbf{x}_{N+k}) \approx y_{n+k}$$

- Escolheremos o modelo com o melhor poder preditivo.

- O modelo é utilizado apenas para criar bons algoritmos para prever bem novas observações.
- Muitas vezes, não há modelo probabilístico explícito por trás dos algoritmos utilizados.

# Função de risco

---

- Seja  $g(\mathbf{x})$  a função utilizada para previsão.
- Para uma nova observação  $(\mathbf{x}, y)$ , podemos definir o risco de um modelo preditivo por

$$R_g = E[y - g(\mathbf{x})]^2$$

- Esta função de risco é a perda quadrática esperada e será dita risco quadrático.
- Quanto menor o risco melhor o modelo, segundo a perda escolhida.

# Função de risco

---

- Podemos mostrar que

$$\begin{aligned} R_g &= E[y - g(\mathbf{x})]^2 \\ &= E\{[y - E(y \mid x)]^2\} + E\{[E(y \mid x) - g(\mathbf{x})]^2\} \end{aligned}$$

- Condicional a  $\mathbf{x}$ , temos que  $g(x) = E(y \mid x)$  minimiza o risco.
- Se  $X$  visto como aleatório temos o mesmo resultado com a esperança também tomada na distribuição de  $\mathbf{x}$ .

# Modelagem e previsão

# Modelo global e modelo local (perda quadrática)

Outras relações mais flexíveis que a regressão linear poderiam ser usadas aqui.

- Vimos que  $E(y | x)$  minimiza a perda quadrática.
- Podemos pensar em duas soluções:
  - (i) Regressão:  $\hat{g}(x) = \hat{\beta}_0 + \hat{\beta}_1, \dots + \hat{\beta}_p x_p$ ;
  - (ii) Vizinhos próximos:  $\hat{g}(x) = \text{media}(y_i | x_i \in V_k(x))$ .

Para  $N$  grande a média empírica irá convergir para a teórica. Porém a **taxa de convergência é mais lenta quando  $p$  cresce**.

- Aproxima-se a media teórica usando a média empírica de dados de treinamento.
- Considere-se apenas os  $k$  vizinhos mais próximos.

# Aprendizado supervisionado

---

- Considere interesse em estimar  $g(\mathbf{x})$  usando dados  $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)$  e a relação

$$y = g(\mathbf{x}) + \epsilon.$$


- Dados de treinamento  $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)$  alimentam um algoritmo que produz outputs  $\hat{g}(x_i)$ ;
- O erro  $y_i - \hat{g}(x_i)$  realimenta o algoritmo de modo a aperfeiçoá-lo.



# Dados de treinamento e teste

---

- Note que se usamos apenas os dados de treinamento para escolher o melhor modelo de regressão podemos ter sobreajuste.
- Por exemplo um polinômio com  $n-1$  graus ajusta os dados perfeitamente.
- Mas esse modelo não seria útil para prever fora da amostra de treinamento.



# Dados de treinamento e teste

---

- Definimos então um conjunto de teste.
- Este não é usado para estimar parâmetros, apenas para calcular o risco do modelo.
- Por exemplo,

$$R_g = \sum_{j=1}^M (y_{N+j} - \hat{g}(\mathbf{x}_{N+j}))^2$$

# Dados de teste

---

- Pode ser escolhido de forma aleatória dentre todos os dados observados.
- Pode-se definir por exemplo 70% dos dados para treinamento e 30% para teste.
- Validação cruzada (leave-one-out):

$$R_g = \sum_{i=1}^{N+M} (y_i - \hat{g}_{-i}(\mathbf{x}_i))^2,$$

onde  $g_{-i}$  foi estimada usando todos os dados menos a  $i$ -ésima observação.

Previsão fora da amostra de treinamento

# Previsão no caso de regressão múltipla

---

Vimos que no caso de regressão simples um valor predito é dado por

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

Vimos também que extrapolação pode ser perigoso.

Por exemplo, o comportamento fora do intervalo de  $x$ 's observados pode ser muito diferente de uma reta!

Se a previsão é feita fora do intervalo  $(\min(x), \max(x))$  chamamos extrapolação.

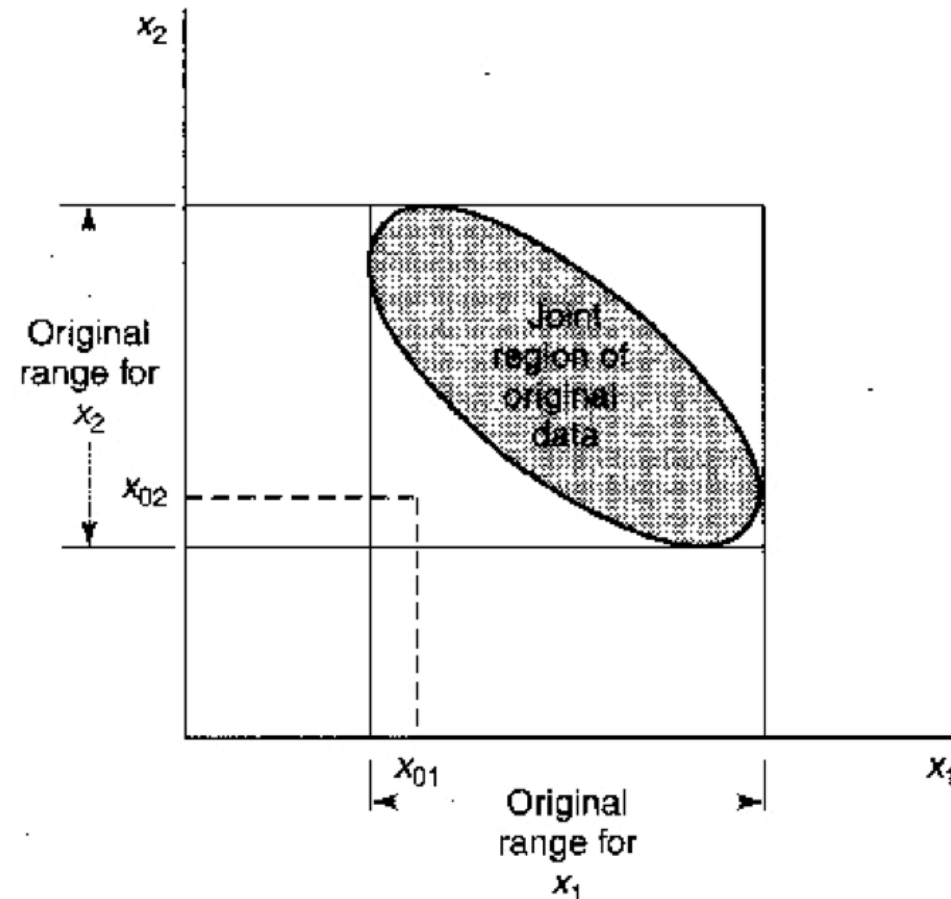
No caso de regressão múltipla,  
temos  $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_k$ .

Como saber se estamos  
extrapolando?

# Região de previsão

---

- Em regressão múltipla é difícil saber se  $x_0$  está ou não dentro do domínio dos  $x$ 's observados ou se trata-se de uma extrapolação.
- Testar cada componente  $x_{0j}$  não é suficiente!



# Região de previsão

---

Considere a matriz  $H = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ .

$h_{max} = \max\{h_{ii}\}$  está no limite da região do domínio observado de  $\mathbf{X}$ .

Portanto, para verificar se  $x_0$  está dentro da região de previsão basta verificar se

$$h_{00} = x_0'(\mathbf{X}\mathbf{X})^{-1}x_0 < h_{max}.$$

Caso contrário temos uma extrapolação!

# Prevendo para um novo valor de $x = x_0$

---

```
##### previsão #####  
beta.hat = ajuste2$coef  
  
range(X[,2]) ##### 234289 554894  
range(X[,3]) ##### 107608 130081  
X0 = c(1,300000,119000)  
  
y0.hat = t(X0)%*%beta.hat ##### 59137.06
```

Mas temos uma  
extrapolação???


```
##### calculando h00 #####  
  
XX = cbind(rep(1,16),X[,-1])  
max(hatvalues(ajuste2)) ##### 0.3384269  
t(X0)%*%solve(t(XX)%*%XX)%*%X0 ##### 4.66992
```

SIM!!




# Exemplo: nem sempre o modelo correto tem o melhor poder preditivo

- Considere o modelo de regressão polinomial
  - (i)  $y = x^t \beta + \epsilon$ ;
  - (ii)  $\beta = (0, 3, 2, 0.2, 0.1, 0.1)$  e  $x = (1, x, x^2, \dots, x^5)$ ;
  - (iii)  $\epsilon \sim N(0, 1)$ .
- Vamos ajustar um modelo polinomial de ordem 2 e o modelo correto de ordem 5.



Neste exemplo, temos 10 pontos de treinamento e 100 pontos de teste.

# Exemplo: nem sempre o modelo correto tem o melhor poder preditivo



- Para 100 pontos de teste o erro quadrático médio do modelo de ordem 2 é **111** enquanto para o modelo de ordem 5 é **437**.

# Seleção de variáveis

# Métodos forward, backward e stepwise

---

- O número de modelos possíveis no modelo de regressão quando temos  $p$  covariáveis é  $2^p$ .
- Quando  $p$  cresce é inviável selecionar variáveis apenas olhando para análises descritivas ou ajustando todos os modelos. E.g.  $2^{10} = 1024$ .
- **Método forward, backward e stepwise:** algoritmos sequenciais nos quais uma variável por vez é introduzida no modelo.

A variável é escolhida dependendo de algum critério de ajuste.

O número de modelos testados neste algoritmo é  $1 + p(p + 1)/2$ .

# Ideia dos algoritmos

---

- **Seleção Forward:** começa com nenhum preditor; sequencialmente adiciona o preditor mais importante no modelo; para quando não há melhora na medida de interesse.
- **Seleção Backward:** começa com todos os preditores no modelo e sequencialmente remove o preditor que menos contribui para o modelo; para quando todos os preditores do modelo são significativos.
- **Seleção stepwise:** combina seleção forward com backward; começa com nenhum preditor; sequencialmente adiciona o preditor que mais contribui para o modelo; após incluir uma variável ele remove variáveis que possivelmente não são mais necessárias no modelo.

# Exemplo: marketing

---

- Vamos analisar o banco de dados marketing do pacote datarium.
- A base contém o impacto nas vendas do gasto com 3 tipos de propagandas: youtube, facebook e jornal. Dimensão: 200 por 3.
- **Objetivo do ajuste:** medir o impacto do gasto nas vendas.
- Vamos dividir os dados em treinamento e teste.

```
set.seed(123)
training.samples <- marketing$sales %>%
  createDataPartition(p = 0.8, list = FALSE)
train.data <- marketing[training.samples, ]
test.data <- marketing[-training.samples, ]
```

	youtube	facebook	newspaper	sales
1	276.12	45.36	83.04	26.52
2	53.40	47.16	54.12	12.48
3	20.64	55.08	83.16	11.16
4	181.80	49.56	70.20	22.20

# Exemplo: marketing

- Modelo para todas as variáveis.

```
Model1 <- lm(sales ~ youtube + facebook + newspaper, data = train.data)
summary(model)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	3.391883	0.440622	7.698	1.41e-12	***
youtube	0.045574	0.001592	28.630	< 2e-16	***
facebook	0.186941	0.009888	18.905	< 2e-16	***
newspaper	0.001786	0.006773	0.264	0.792	

- Modelo sem newspaper.

```
Model2 <- lm(sales ~ youtube + facebook, data = train.data)
summary(model2)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	3.434458	0.408770	8.402	2.32e-14	***
youtube	0.045582	0.001587	28.725	< 2e-16	***
facebook	0.187877	0.009202	20.418	< 2e-16	***

# Exemplo: marketing

Erro preditivo:

```
predictions <- model1 %>% predict(test.data)
RMSE(predictions, test.data$sales)
1.590096

predictions <- model2 %>% predict(test.data)
RMSE(predictions, test.data$sales)
1.57911
```

Podemos melhorar o modelo para previsão? Vamos considerar o modelo com interações.

```
model.full <- lm(sales ~ youtube * facebook * newspaper, data = train.data)
summary(model.full)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	7.269e+00	6.552e-01	11.094	< 2e-16	***
youtube	2.136e-02	3.044e-03	7.015	6.81e-11	***
facebook	2.571e-02	1.861e-02	1.381	0.169	
newspaper	2.617e-02	1.961e-02	1.334	0.184	
youtube:facebook	9.526e-04	9.089e-05	10.481	< 2e-16	***
youtube:newspaper	-8.706e-05	8.555e-05	-1.018	0.310	
facebook:newspaper	-2.132e-04	4.473e-04	-0.477	0.634	
youtube:facebook:newspaper	2.865e-07	2.050e-06	0.140	0.889	

```
RMSE(predictions, test.data$sales)
1.020196
```



# Exemplo: marketing

- Erro preditivo do modelo com interações:

```
predictions <- model.full %>% predict(test.data)
RMSE(predictions, test.data$sales)
1.020196
```

- Esse modelo tem todas as variáveis e interações. Podemos ajustar um modelo mais simples?

```
step.model2 <- stepAIC(model.full, direction = "both", trace = FALSE)
summary(step.model2)
predictions <- step.model2 %>% predict(test.data)
RMSE(predictions, test.data$sales)
1.007243
```

## Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	7.526e+00	3.608e-01	20.860	<2e-16	***
youtube	2.099e-02	1.773e-03	11.838	<2e-16	***
facebook	1.867e-02	1.075e-02	1.736	0.0845	.
newspaper	1.747e-02	7.368e-03	2.371	0.0190	*
youtube:facebook	9.579e-04	5.211e-05	18.382	<2e-16	***
youtube:newspaper	-7.101e-05	3.306e-05	-2.148	0.0333	*

# Exemplo: marketing

- Caminho do método stepwise:

`step.model2$anova`

Stepwise Model Path

Analysis of Deviance Table

Initial Model:

`sales ~ youtube * facebook * newspaper`

Final Model:

`sales ~ youtube + facebook + newspaper + youtube:facebook + youtube:newspaper`

	Step	Df	Deviance	Resid. Df	Resid. Dev	AIC
1				154	209.8617	57.93407
2 - youtube:facebook:newspaper	1	0.02662091		155	209.8883	55.95462
3 - facebook:newspaper	1	0.68097906		156	210.5693	54.47938

# Transformação da variável resposta

---

Suponha que desejamos transformar a variável  $y$  para obter variância constante.

Porém não sabemos qual transformação usar.

O método de Box-Cox transforma  $y$  para  $g_\lambda(y)$  onde

$$g_\lambda(y) = \begin{cases} \frac{y^\lambda - 1}{\lambda} & \text{se } \lambda \neq 0 \\ \log(y) & \text{se } \lambda = 0 \end{cases}$$

Para  $y > 0$ ,  $g$  é contínua em  $\lambda$ . Podemos usar máxima verossimilhança para estimar  $\lambda$ .

No R: usar a função `boxcox(ajuste)` da biblioteca *MASS*.



# Exemplo: sales

##### transformação Box-Cox #####

```
library(MASS)
```

```
boxcox(model.full)
```

```
transf.y = boxcox(model.full,lambda = seq(1.5, 2, 1/20)) ### refinando a busca
```



# Exemplo: preço de venda

##### transformação Box-Cox #####

```
lambda0 = transf.y$x[transf.y$y==max(transf.y$y)]
train.data$salesnew = train.data$sales^lambda0
```

```
model.full2 <- lm(salesnew ~ youtube*facebook*newspaper, data = train.data)
summary(model.full)
summary(model.full2)
```

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	7.269e+00	6.552e-01	11.094	< 2e-16 ***
youtube	2.136e-02	3.044e-03	7.015	6.81e-11 ***
facebook	2.571e-02	1.861e-02	1.381	0.169
newspaper	2.617e-02	1.961e-02	1.334	0.184
youtube:facebook	9.526e-04	9.089e-05	10.481	< 2e-16 ***
youtube:newspaper	-8.706e-05	8.555e-05	-1.018	0.310
facebook:newspaper	-2.132e-04	4.473e-04	-0.477	0.634
youtube:facebook:newspaper	2.865e-07	2.050e-06	0.140	0.889

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.167 on 154 degrees of freedom  
Multiple R-squared: 0.9675, Adjusted R-squared: 0.966  
F-statistic: 654.9 on 7 and 154 DF, p-value: < 2.2e-16

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	3.745e+01	5.485e+00	6.828	1.87e-10 ***
youtube	1.441e-01	2.548e-02	5.654	7.42e-08 ***
facebook	-1.688e-01	1.558e-01	-1.084	0.280
newspaper	5.196e-02	1.642e-01	0.316	0.752
youtube:facebook	1.809e-02	7.609e-04	23.777	< 2e-16 ***
youtube:newspaper	-1.885e-04	7.162e-04	-0.263	0.793
facebook:newspaper	1.316e-03	3.744e-03	0.351	0.726
youtube:facebook:newspaper	-2.995e-06	1.716e-05	-0.175	0.862

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.772 on 154 degrees of freedom  
Multiple R-squared: 0.9901, Adjusted R-squared: 0.9896  
F-statistic: 2191 on 7 and 154 DF, p-value: < 2.2e-16